

TP OPTIMISATION

Minimisation par optimisation proximale

27 mars 2018

1 Implémentation de Ista

Dans un premier temps, nous allons implémenter l'algorithme ISTA. Pour cela nous avons besoin du lemme suivant :

Lemme 1.1 *Nous avons, $\forall \gamma, \lambda \geq 0$, $prox_{\lambda g}^\gamma = prox_g^{\lambda \gamma}$.*

Dans cette partie nous allons nous concentrer sur la preuve de ce lemme.

D'après le cours nous avons l'existence et l'unicité de $prox_{\lambda h}^\gamma$ pour toute fonction h de $\mathbb{R}^d \mapsto \mathbb{R}$. On en déduit l'existence d'un unique couple $(y_0, y_1) \in \mathbb{R}^d \times \mathbb{R}^d$ vérifiant :

$$y_0 = \operatorname{argmin}_{\mathbb{R}^d} \{g(y) + (2\lambda\gamma)^{-1} \|x - y\|^2\} \text{ et } y_1 = \operatorname{argmin}_{\mathbb{R}^d} \{\lambda g(y) + (2\gamma)^{-1} \|x - y\|^2\}$$

Par définition de y_0 , on a $\forall y \in \mathbb{R}^d$,

$$g(y_0) + (2\lambda\gamma)^{-1} \|x - y_0\|^2 \leq g(y) + (2\lambda\gamma)^{-1} \|x - y\|^2$$

En multipliant cette inégalité par λ et en prenant l'infimum à gauche sur y on obtient,

$$y_0 \in \operatorname{argmin}_{\mathbb{R}^d} \{\lambda g(y) + (2\gamma)^{-1} \|x - y\|^2\}$$

Par unicité de y_1 , on obtient : $y_0 = y_1$. D'où le résultat annoncé.

Grâce à ce résultat, nous implémentons l'algorithme avec l'étape :

$$x_{k+1} = prox_g^{\lambda \gamma} \{x_k - \gamma \nabla f(x_k)\}$$

2 Acquisition comprimée

Dans le cadre d'un signal comprimé, on s'intéresse désormais au minimum de la fonction F défini par :

$$F(x) = f(x) + g(x), \text{ avec } f : x \mapsto \|y - Ax\|^2 \text{ et } g : x \mapsto \sum_{i=1}^d \|x_i\|.$$

Maintenant calculons la différentielle de f . Nous avons l'égalité suivante :

$$\forall (x, h) \in \mathbb{R}^d \times \mathbb{R}^d, f(x+h) - f(x) = 2\langle A^*Ax - A^*y | h \rangle + o(h)$$

De cette dernière égalité, nous en déduisons : $\nabla f(x) = 2A^*(Ax - y)$.

Ainsi par Cauchy-Schwarz f est $2\text{norm}(A^*A)$ -lipschitzienne.

Considérons maintenant une fonction h convexe, sci et propre sur \mathbb{R}^d sous la forme $h(x) = \sum_{i=1}^d h_i(x_i)$.

Par définition, $\text{prox}_h^\gamma = \underset{\mathbb{R}^d}{\operatorname{argmin}} \{h(y) + (2\gamma)^{-1} \|x - y\|^2\} = \underset{\mathbb{R}^d}{\operatorname{argmin}} \left\{ \sum_{i=1}^d [h_i(x_i) + (2\gamma)^{-1} (x_i - y_i)^2] \right\}$.

Prenons $x = (\text{prox}_{h_i}^\gamma)_{i \in \{1, \dots, d\}}$, par définition de x ,

$$\forall \tilde{x} \in \mathbb{R}^d, h_i(x_i) + (2\gamma)^{-1} (x_i - y_i)^2 \leq h_i(\tilde{x}_i) + (2\gamma)^{-1} (\tilde{x}_i - y_i)^2$$

$$\text{D'où, } \sum_{i=1}^d [h_i(x_i) + (2\gamma)^{-1} (x_i - y_i)^2] \leq \sum_{i=1}^d [h_i(\tilde{x}_i) + (2\gamma)^{-1} (\tilde{x}_i - y_i)^2]$$

En prenant $\tilde{x} = (\text{prox}_{h_i}^\gamma)_{i \in \{1, \dots, d\}}$, on en déduit l'inégalité inverse. Par unicité de prox_h^γ on en déduit que $\text{prox}_h^\gamma = (\text{prox}_{h_i}^\gamma)_{i \in \{1, \dots, d\}}$.

Considérons la fonction $\Phi(t) = |t|$, pour tout $t \in \mathbb{R}$.

Montrons que pour tout $u \in \mathbb{R}$ et $\gamma \leq 0$, $t_* = \underset{\mathbb{R}^d}{\operatorname{argmin}} \{ \|t\| + (2\gamma)^{-1} (t - u)^2 \}$ si et seulement si $t_* \in u - \gamma \partial \Phi(t_*)$.

Nous avons la série d'équivalences suivantes :

$$t_* = \underset{\mathbb{R}^d}{\operatorname{argmin}} \{ \|t\| + (2\gamma)^{-1} (t - u)^2 \}$$

$$\iff t_* \text{ minimum de } \tilde{\Phi}_\gamma$$

$$\iff 0 \in \partial \tilde{\Phi}_\gamma(t_*) = t_* - u + \partial \Phi(t_*) \text{ d'après la proposition 8 du cours}$$

$$\iff t_* \in u - \gamma \partial \Phi(t_*)$$

Déterminons désormais la sous-différentielle de Φ sur \mathbb{R} .

Par définition de la sous-différentielle d'une application, pour $x \in \mathbb{R}$,

$$x \in \partial \mathbb{R} \iff |u| - |x| \geq (u - x)y$$

Cela équivaut à :

$$\begin{aligned} & |u| - uy \geq |x| - xy \\ \iff & o(u) = u(\text{sign}(u) - y) \geq x(\text{sign}(x) - y) \end{aligned}$$

Donc si $x \neq 0$, la dernière égalité montre que $y = \text{sign}(x)$

En condensant, nous avons : $\partial \Phi(x) = \text{sign}(x)$

Si $x = 0$, alors $\forall u$, $u(\text{sign}(u) - y) \geq 0$, donc $1 \geq y$ et $-1 \leq y$.

dans ce cas, on vérifie que $\partial \Phi(0) = [-1, 1]$.

D'après la question 4.b., nous avons la relation : $t_* = \text{prox}_\Phi^\gamma(u) \in u - \gamma \partial \Phi(t_*)$.

Cas 1 : si $t_* \leq 0$, alors $t_* = u + \gamma$ possible si $u + \gamma \geq 0$.

Cas 2 : si $t_* \geq 0$, alors $t_* = u - \gamma$ possible si $u \geq \gamma$.

Cas 3 : si $t_* = 0$, alors $t_* \in [u - \gamma, u + \gamma]$, cela n'est seulement possible pour $|u| \leq \gamma$.
 Nous pouvons vérifier que :

$$\text{prox}_{\Phi}^{\gamma}(u) = \left(1 - \frac{\lambda}{|u|}\right)^+ u$$

D'après la question 4.a., nous avons :

$$\text{prox}_g^{\gamma}(u) = (\text{prox}_{\Phi}^{\gamma})_{i \in \{1, \dots, d\}}$$

La question 4.d. conclut :

$$\text{prox}_g^{\gamma}(u) = \left(\left(1 - \frac{\lambda}{|x_i|}\right)^+ x_i \right)_{i \in \{1, \dots, d\}}$$

.

Nous pouvons désormais implémenter les fonctions prox_g^{γ} afin de tester nos algorithmes.
 Commençons par appliquer la fonction ISTA pour minimiser la fonction F . Nous obtenons l'image suivantes pour $\lambda_{l1} = 1$ et $n_{it} = 1000$:




FIGURE 1 – Image obtenue pour $\lambda_{l1} = 1$ et $n_{it} = 1000$

Nous constatons que l'image reste extrêmement bruitée, en effet la valeur de λ_{l1} n'est pas optimale et le nombre n_{it} n'est pas suffisamment grand pour avoir une image nette.

Intéressons-nous maintenant à la vitesse de convergence de l'algorithme ISTA. D'après notre cours nous savons que cet algorithme à une convergence de l'ordre de $O(\frac{1}{k})$, où k est le nombre d'itérations. Numériquement, montrons que $F(x_k) = F(x_*) + O(\frac{1}{k})$. Pour cela, nous utilisons la fonction `numpy.polyfit` afin d'approcher $kF(x_k)$ par un polynôme de degré 1 (noté P). En effet, il nous suffit de montrer que $kF(x_k) = kF(x_*) + O(1)$ pour conclure. Donc intuitivement le coefficient dominant de P sera proche de $F(x_*)$. Nous vérifions que $kF(x_k) - P(k)$ reste borné en traçant la courbe en fonction de k .

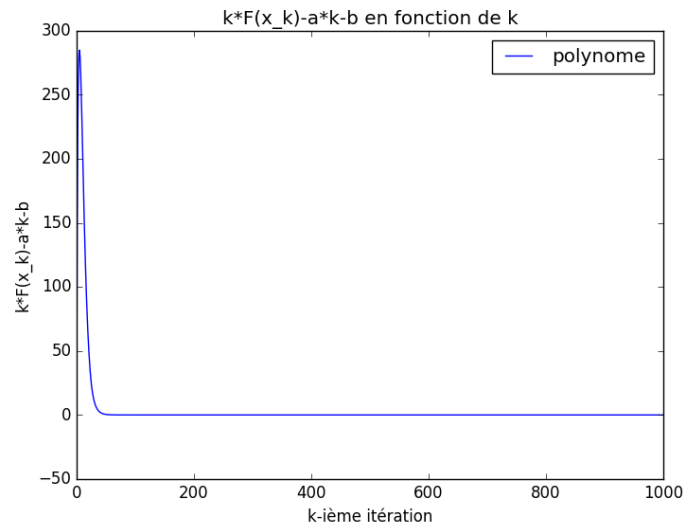



FIGURE 2 – Valeur de $|kF(x_k)|$ en fonction de k

La courbe semble tendre vers $o(1)$, cela confirme numériquement le résultat de notre cours.

Essayons de trouver une valeur de λ_{l1} permettant de débruité efficacement notre image. Afin de trouver ce λ_{l1} nous commençons par afficher les images pour des λ_{l1} d'ordre de grandeur bien distincts. Nous obtenons les figures suivantes :



(a) $\lambda_{l1} = 0.4$



(b) $\lambda_{l1} = 0.1$



(c) $\lambda_{l1} = 0.03$



(d) $\lambda_{l1} = 0.005$

FIGURE 3 – Image pour $n_{it} = 1000$ en fonction de λ_{l1}

Nous constatons qu'une valeur de $\lambda_{l1} = 0.03$ donne un meilleur rendu, bien que les différences entre $\lambda_{l1} = 0.1$ et $\lambda_{l1} = 0.03$ soient minimales. Nous pouvons supposer que la valeur optimale de λ recherchée se situe dans l'intervalle $[0.03, 0.1]$. Dans le cadre de notre problème, nous cherchons une solution x_{min} du problème de minimisation :

$$\operatorname{argmin}_{\mathbb{R}^d} \{ \|y - Ax\|^2 + \lambda g(x) \}$$

L'objectif du terme $\lambda g(y)$ est de régulariser les solution afin d'obtenir un problème bien posé au sens d'Hadamard. Intuitivement, on souhaite que la solution ne varie pas brusquement lors d'une légère perturbation de y . Cependant λ ne doit pas être trop grand pour ne pas complètement modifier le problème initial.